

Partie 1 : Les Fondations du Machine Learning

Exercice 1 : Comprendre le Problème et Choisir la Bonne Approche

1. Prédiction des prix des actions >> Apprentissage supervisé parce que :

- On prédit une valeur numérique précise (le prix futur) à partir de données historiques étiquetées (prix passés + actualités).
- Tâche de régression car prédiction continue, Besoin de prédire un résultat connu (prix = label).

2. Organisation d'une bibliothèque >> Apprentissage non supervisé parce que :

- On cherche à découvrir des catégories *sans* étiquettes prédéfinies (pas de "bonne réponse").
- C'est un problème de **clustering** (groupement naturel des livres par similarité). Découverte de patterns *sans* référence externe.

3. Programmer un robot aspirateur >> Apprentissage par renforcement parce que :

- Le robot apprend par essais/erreurs, en maximisant les récompenses (nettoyage) et minimisant les pénalités (collisions).
- Interaction continue avec un **environnement dynamique**. Apprentissage via feedback environnemental.

Exercice 2 : Définir un Plan d'Action pour un Projet de Prédiction

1. Définition du Problème : Prédire le possible défaut de paiement client dans les 12 mois suivant l'octroi d'un prêt à partir de ses données socio-économiques et son historique financier.

2. Données Nécessaires (Features)

Catégorie	Features Clés	Valeurs (ex)	Utilité
Informations Client	Âge	32, 45, 60	Corrélation avec stabilité financière.
	Statut d'emploi	CDI, freelance, retraité	Évaluation de la stabilité des revenus.
Finances	Revenu annuel	45 000 €, 120 000 €	Capacité de remboursement.

	Dettes existantes (ratio DTI)	0.3, 0.6	Niveau d'endettement.
Historique Crédit	Score de crédit (FICO/ Score Banque)	580, 720, 810	Risque historique.
	Nombre de retards de paiement	0, 2, 5	Comportement passé.
Détails du Prêt	Montant du prêt	10 000 €, 250 000 €	Exposition au risque.
	Durée du prêt	12 mois, 60 mois	Période de risque.

3. Sources de Données

Source	Données Recueillies
Formulaire de demande interne	Âge, emploi, revenu
Historique Bancaire	Comptes, prêts passés, retards
Organismes de Crédit / Autorités	Score FICO, dettes externes / AMF
Réseaux Sociaux !	LinkedIn, Facebook

4. Étapes Clés du Projet

1. Collecte

- Intégration des données client.
- Data cleaning des valeurs manquantes. Exemple : imputation par la médiane pour le revenu.

2. Feature Management

- Créer des ratios comme la solvabilité via le ratio de liquidité, le ratio de dettes, le ratio de rentabilité et le ratio de couverture des intérêts.
- Normaliser les features (Ex : StandardScaler).

3. Modélisation

- **Algorithme** : XGBoost, e comporte donc remarquablement dans les compétitions d'apprentissage automatique(Machine Learning), mais pas seulement grâce à son principe d'auto-amélioration séquentielle
- **Métrique** : Focus sur le **Recall** (éviter les faux négatifs = clients risqués acceptés).

4. Déploiement

- API REST pour intégration au système de validation des prêts.
- Dashboard SHAP pour expliquer les décisions aux conseillers.

Exercice 3 : Comment Savoir si Votre Modèle est Performant ?

Type	Objectif	Outils Clés	Métrique Phare
Supervisé	Prédire un label	Matrice de confusion, AUC-ROC	F1-Score (classification)
Non supervisé	Découvrir des patterns	Score de Silhouette, Dendrogramme	Silhouette > 0.5
Renforcement	Maximiser une récompense	Récompense cumulée	Taux de réussite > 80%

A noter

- **Supervisé** : focus sur les erreurs coûteuses avec intégration faux positifs/négatifs.
- **Non supervisé** : validations qualitative + quantitative (pas de "bonne réponse").
- **Renforcement** : optimisation progressive par essais/erreurs.

1. Métriques de classification courantes

1. **Accuracy** : % de prédictions correctes (vrais positifs + vrais négatifs) sur l'ensemble des prédictions.
2. **Precision** : proportion de clients prédits comme "solvable" qui le sont vraiment.
3. **Recall** : proportion de clients vraiment identifiés comme solvables.

Contexte bancaire

La **précision** mesure la capacité du modèle à éviter les **faux positifs** soit des clients prédits comme solvables mais qui ne remboursent pas. Une faible précision signifie que la banque accorde des prêts à risque, ce qui peut entraîner des pertes financières.

Conclusion

>> Accepter un client qui ne remboursera pas (faux positif) est généralement plus grave que refuser un client solvable (faux négatif).

Raison : un **faux positif** entraîne une perte financière directe (prêt non remboursé) vs un **faux négatif** représente une opportunité manquée (moins de profit, mais pas de perte).

>> Préférer un modèle avec une **haute précision** pour minimiser les risques de défaut, même au prix d'un rappel plus faible.

2. Modèle de clustering (non supervisé)

1. Méthode du Coude (Elbow Method)

- Principe : on trace l'inertie (somme des distances au carré des points par rapport à leur centroïde) en fonction du nombre de clusters (k). Le "coude" (point où la courbe plie) suggère le k optimal.
- Avantage : simple à visualiser.
- Limite : subjectif comme le coude n'est pas toujours clair.

>> Si l'inertie chute brutalement jusqu'à $k=3$ puis se stabilise, on retient 3 clusters.

2. Score de Silhouette

- Principe : calcule pour chaque point le **a** (distance moyenne aux autres points du même cluster (cohésion)), le **b** (distance moyenne au cluster le plus proche)
Le score global est la moyenne des scores par point, compris entre **-1 (pire)** et **+1 (meilleur)**.
- Avantage : combinaison cohésion/séparation des clusters.
- Limite : coûteux pour les grands jeux de données.

>> Un score de 0.7 indique des clusters bien séparés et denses.

3. Indice de Davies-Bouldin

- Principe : compare la distance intra-cluster (compacité) à la distance inter-clusters (séparation). Plus le score est **proche de 0**, meilleurs sont les clusters.
- Avantage : Rapide à calculer.
- Limite : Peut favoriser des clusters convexes.

>> Un score de 0.3 est meilleur qu'un score de 0.8.

Application aux livres

- Objectif : grouper des livres par similarité (thème, style, etc.).
- Approche : on utilise le score de silhouette pour vérifier que les clusters sont homogènes (ex. : livres de SF bien séparés des livres historiques). Si le nombre de thèmes est inconnu, appliquer la méthode du coude pour estimer k .